



Univerzitet u Beogradu
Matematički fakultet

Projekat iz Računarske inteligencije

Primena genetskog algoritma u proceni nedostajućih vrednosti u randomizovanom kompletnom blok dizajnu

Mentor:

Asistent Stefan Kapunac

Profesor:

Vladimir Filipović

Studenti:

Dragana Katić 91/2021

Đurđa Milošević 84/2021

Smer: Informatika

Datum: avgust 2025

Sadržaj

1	Uvod	2
2	Teorijska osnova	3
2.1	Randomizovani kompletni blok dizajn (RCBD)	3
2.2	Genetski algoritam (GA)	4
3	Opis problema	5
4	Opis rešenja	5
4.1	Kodiranje jedinke (hromozoma)	6
4.2	Funkcija prilagođenosti	7
4.3	Selekcija	7
4.4	Genetske operacije: ukrštanje i mutacija	8
4.5	Implementacija genetskog algoritma (GA)	9
5	Eksperimentalni deo	10
5.1	Pokretanje genetskog algoritma nad veštačkim podacima . . .	11
5.1.1	GA za jednu nedostajuću vrednost	12
5.1.2	GA za dve nedostajuće vrednosti	13
5.2	Pokretanje genetskog algoritma nad stvarnim podacima . . .	15
5.3	Genetski algoritam iz literature	17
5.4	Upoređivanje razvijenog GA sa onim iz literature	17
6	Zaključak	20
7	Literatura	21

1 Uvod

Randomizovani potpuni blok dizajn (RCBD) predstavlja jedan od najčešće korišćenih eksperimentalnih dizajna, naročito za statističke eksperimente u agrikulturi, biologiji i industriji. Njegova glavna prednost je kontrola varijabilnosti između eksperimentalnih jedinica pomoću blokova. Bitna karakteristika dizajna je da se svaki tretman, odnosno faktor čiji se uticaj ispituje u eksperimentu, pojavljuje tačno jednom u svakom bloku. Podaci se organizuju u tabelu dimenzija broj tretmana $\times$ broj blokova. Za analizu i prikupljanje rezultata ovako dizajniranog istraživanja koristi se *two-way ANOVA* test [1].

U praksi, RCBD podaci često sadrže nedostajuće vrednosti usled grešaka u merenju, neuspelih merenja ili drugih faktora. Prisustvo takvih vrednosti narušava balansiranost dizajna i otežava standardnu statističku analizu.

Do sada su se koristile različite metode za imputaciju: aproksimativne formule bazirane na srednjim vrednostima, regresione metode, veštačke neuronske mreže (ANN), optimizacija rojem čestica (PSO) i genetski algoritmi (GA) [5]. Rad "*Optimum estimation of missing values in randomized complete block design by genetic algorithm*" od Azadeh i saradnika (2013) pokazao je da GA može uspešno proceniti nedostajuće vrednosti u RCBD tabelama, pri čemu su se koristile metrike poput MAPE i Pirsonovog koeficijenta korelacije.

U ovom radu razvijamo sopstvenu implementaciju genetskog algoritma za procenu nedostajućih vrednosti u RCBD tabelama, zasnovanu na idejama iz pomenutog naučnog rada [5]. Implementacija je pisana od nule u Python-u, uz korišćenje funkcije cilja zasnovane na sumi kvadrata grešaka (SSE). Fokus je na razumevanju i demonstraciji metode, kroz testiranje na sintetički generisanim podacima.

2 Teorijska osnova

2.1 Randomizovani kompletni blok dizajn (RCBD)


Statistička istraživanja su prisutna skoro u svim poslovnim i naučnim poljima. Treba razumeti da se pod statističkim eksperimentom podrazumeva istraživanje koje uključuje uzročno-posledičnu vezu. Dakle, ispituje se da li neki faktor kada se primeni nad ispitanicima prouzrokuje neki efekat.

Pošto je važno da rezultati eksperimenata budu precizni, pouzdani i nepristrasni, dolazi se do zaključka da ih je potrebno nekako dizajnirati.

Randomizovani kompletni blok dizajn (RCBD) je dizajn eksperimenta koji se u većini slučajeva koristi u statističkim istraživanjima u poljima agrikulture, biologije i industrije, gde su faktori pod uticajem varijacija koje nisu predmet posmatranja. Cilj RCBD-a je da eliminiše ili smanji uticaj tzv. „sporednih faktora“ koji mogu uticati na rezultate eksperimenta, tako što se eksperimentalne jedinice grupišu u blokove unutar kojih su ti faktori ujednačeni [2].

U RCBD-u svaki tretman (npr. tip đubriva, lek, uslov okoline) se pojavljuje tačno jednom u svakom bloku. Dakle, ako postoji t tretmana i b blokova, broj posmatranja je $t \times b$.

Radi boljeg razumevanja strukture RCBD eksperimenta, na slici 1 prikazan je tipičan primer RCBD rasporeda za sedam tretmana raspoređenih u tri bloka [3]:



Slika 1: *Primer rasporeda tretmana u randomizovanom kompletnom blok dizajnu*

Slika prikazuje kako se tretmani ($T_1, T_2, \dots, T_7$) nasumično raspoređuju unutar svakog bloka (B_1, B_2, B_3), pri čemu se svaki tretman pojavljuje tačno jednom po bloku. Ovakav raspored omogućava da se efekti tretmana analiziraju nezavisno od efekata blokova, uz zadržavanje statističke snage eksperimenta. Ključne prednosti RCBD-a su jednostavnost primene, efikasna kontrola sporednih faktora i dobra interpretabilnost rezultata.

RCBD se često analizira primenom analize varijanse (ANOVA), uz pretpostavku da su svi podaci dostupni. Međutim, u stvarnim eksperimentalnim uslovima može doći do gubitka podataka – npr. merenje nije uspešno obavljeno, eksperimentalna jedinica je uništena ili je rezultat zabeležen pogrešno. Takvi nedostaci onemogućavaju direktnu primenu ANOVA i drugih standardnih statističkih metoda, jer one zahtevaju kompletnu tabelu. Iz tog razloga se istražuju metode za procenu nedostajućih vrednosti u RCBD tabelama [5]. U ovom projektu fokus je upravo na razvoju jedne takve metode – na bazi genetskog algoritma.

2.2 Genetski algoritam (GA)

Genetski algoritam (GA) je heuristička optimizaciona tehnika inspirisana principima prirodne selekcije i genetike, razvijena u okviru evolutivnog računanja [4]. GA se koristi za pronalaženje dobrih (često približnih) rešenja u kompleksnim optimizacionim problemima gde klasične metode ne daju zadovoljavajuće rezultate ili nisu primenljive.

Genetski algoritam je osmišljen tako da imitira proces evolucije koja podrazumeva promenu naslednih osobina populacije kroz generacije. Osnovna ideja GA jeste da se potencijalna rešenja problema predstavljaju kao hromozomi – jedinke (nizovi podataka), koji se grupišu u populaciju. Na osnovu vrednosti ciljne funkcije (*eng. fitness*), jedinke se selektuju za razmnožavanje nakon čega se ukrštaju (*eng. crossover*) i mutiraju. Cilj je da se vremenom (kroz više generacija) evoluiraju populacija u pravcu boljih rešenja.

U kontekstu procene nedostajućih vrednosti u RCBD-u, svaka jedinica predstavlja moguću kombinaciju vrednosti koje nedostaju. Ciljna funkcija meri koliko je ta pretpostavljena vrednost „dobra“, u smislu minimizacije greške (npr. u našem slučaju, sume kvadratnih grešaka – SSE) u odnosu na poznate vrednosti. GA iterativno menja populaciju rešenja dok ne pronađe ono koje najbolje popunjava praznine u RCBD tabeli [5].

Zahvaljujući svojoj fleksibilnosti i sposobnosti da izbegne lokalne minimume, GA predstavlja efikasno rešenje u problemima imputacije podataka gde je broj mogućih kombinacija veliki, a sistemska greška teško modelabilna.

3 Opis problema

U praksi, eksperimentalni podaci dobijeni primenom randomizovanog kompletnog blok dizajna (RCBD) često sadrže nedostajuće vrednosti. One mogu nastati usled tehničkih grešaka, propusta u merenju ili drugih nepredviđenih okolnosti. Prisustvo nedostajućih vrednosti narušava balansiranost dizajna, što otežava primenu standardnih statističkih metoda, koje zahtevaju potpun skup podataka.

Zbog ovoga je neophodno razviti metode za procenu (imputaciju) tih vrednosti, koje će omogućiti pouzdanu analizu eksperimentalnih rezultata. Tradicionalne metode za imputaciju, kao što su zamena prosečnom vrednošću ili regresione tehnike, često ne uzimaju u obzir specifičnu strukturu RCBD podataka, što može dovesti do smanjenja tačnosti procene.

Cilj ovog rada je razvoj i implementacija metode zasnovane na genetskom algoritmu (GA) za preciznu procenu nedostajućih vrednosti u RCBD tabelama. Genetski algoritam, zahvaljujući svojoj sposobnosti da pretražuje veliki prostor mogućih rešenja i da izbegne lokalne minimume, predstavlja obećavajući pristup u rešavanju problema imputacije u složenim eksperimentalnim dizajnima.

U okviru ovog rada, fokus je na proceni jedne ili dve nedostajuće vrednosti u RCBD tabelama, korišćenjem ciljnih funkcija zasnovanih na minimizaciji sume kvadratnih grešaka (SSE). Takođe, razvijena metoda je testirana na sintetički generisanim podacima, kao i na stvarnim podacima preuzetim iz relevantne literature, kako bi se ocenila njena efikasnost i preciznost.

Rezultat ovog pristupa treba da omogući tačniju i robusniju analizu podataka u slučajevima kada kompletni skup podataka nije dostupan, čime se doprinosi unapređenju statističkih metoda za eksperimentalne dizajne.

4 Opis rešenja

Cilj ovog rada je razvoj metode za procenu nedostajućih vrednosti u randomizovanom kompletnom blok dizajnu (RCBD) korišćenjem genetskog algoritma (GA). S obzirom na to da RCBD podaci zahtevaju potpuni i balansiran skup za primenu standardnih statističkih metoda, problem nedostajućih vrednosti predstavlja značajnu prepreku u analizi.

Predloženo rešenje modeluje nedostajuće vrednosti kao hromosome unutar populacije potencijalnih rešenja. Svaki hromozom predstavlja niz bita koji enkodira vrednost koja treba da se imputira na poziciji nedostajuće vrednosti u RCBD tabeli. Ciljna funkcija je definisana preko sume kvadratnih grešaka (SSE) između poznatih i predviđenih vrednosti, koja se minimizira kako bi

se pronašlo optimalno rešenje.

Proces optimizacije uključuje generisanje inicijalne populacije nasumičnih hromozoma, selekciju kandidata putem ruletnog izbora proporcionalnog fitnessa, ukrštanje (crossover) i mutaciju hromozoma kako bi se obezbedila raznovrsnost populacije i izbegli lokalni optimumi. Poseban izazov predstavlja korekcija vrednosti kada postoje dve ili više nedostajućih ćelija, što je rešeno dodatnim izračunavanjem druge vrednosti prema poznatoj formuli.

Metoda je implementirana u Python programskom jeziku, sa funkcionalnostima za generisanje sintetičkih podataka, merenje fitnessa, kao i paralelnu evaluaciju rezultata za različite parametre algoritma. Rezultati dobijeni ovom metodom mogu se koristiti kao početna tačka za statističku analizu, nadomestivši nedostajuće podatke na principima koji poštuju strukturu RCBD dizajna.

Predloženi algoritam pruža fleksibilan okvir koji se može dodatno prilagođavati i unapređivati za složenije eksperimentalne situacije sa većim brojem nedostajućih vrednosti.

4.1 Kodiranje jedinke (hromozoma)

U okviru genetskog algoritma, svaka jedinka (hromozom) predstavlja moguću procenu vrednosti nedostajuće stavke u RCBD tabeli. Za potrebe optimizacije, vrednosti koje treba predvideti kodirane su binarno kao niz bitova.

Svaka jedinka poseduje binarni kod — niz logičkih vrednosti (True ili False) koji se interpretira kao binarni broj. Ovaj binarni broj predstavlja diskretnu aproksimaciju vrednosti nedostajućeg podatka unutar unapred definisanog intervala. Interval se određuje na osnovu postojećih vrednosti u odgovarajućem redu tabele: uzimaju se minimalna i maksimalna vrednost, proširene za malu marginu (epsilon) radi pokrivanja mogućih odstupanja i kako bi se obuhvatili i specijalni slučajevi, kada je nedostajuća vrednost minimalna ili maksimalna vrednost u odgovarajućem redu.

Dekodiranjem binarnog koda u decimalni broj, dobijamo predviđenu vrednost za nedostajući podatak. Na ovaj način, genetski algoritam pretražuje prostor mogućih vrednosti kroz evolutivne operacije kao što su ukrštanje i mutacija, tražeći onu vrednost koja minimizira grešku predikcije.

Pored same vrednosti prve nedostajuće tačke, ukoliko u tabeli postoje dve nedostajuće vrednosti, za drugu se koristi poseban računarski izraz izveden iz analize zavisnosti između redova i kolona RCBD tabele, što omogućava precizniju rekonstrukciju.

Ovako kodirana i predstavljena jedinka omogućava efikasno i precizno optimizovanje vrednosti nedostajućih podataka kroz genetski algoritam.

4.2 Funkcija prilagođenosti

Funkcija prilagođenosti (fitness) meri kvalitet pojedinačne jedinke u populaciji, odnosno koliko je dobro rešenje koje ona predstavlja. U našem slučaju, jedinka predstavlja predikciju nedostajuće vrednosti u RCBD tabeli.

Da bismo izračunali fitness, prvo dekodiramo binarni hromozom u numeričku vrednost koja predstavlja predviđenu vrednost na poziciji koja nedostaje. Zatim se ta vrednost ubacuje u kopiju tabele sa nedostajućim podacima.

Ako u tabeli postoji više od jedne nedostajuće vrednosti, dodatno se računa i predviđena vrednost za drugu nedostajuću poziciju korišćenjem formule izvedene iz matematičkog modela RCBD-a.

Fitness se zatim računa kao negativna vrednost sume kvadrata grešaka (SSE) između cele tabele sa predikcijama i poznate tačne tabele, ali samo za pozicije gde su vrednosti bile prvobitno skrivene (koristeći masku). Na ovaj način, što je SSE manji, fitness je veći (jer uzimamo negativnu vrednost SSE).

Takođe, ukoliko dekodirana vrednost odstupa van dozvoljenog intervala zasnovanog na vrednostima u odgovarajućem redu (tretmanu), fitness se automatski postavlja na negativnu beskonačnost, kako bi se eliminisale neprihvatljive jedinke.

4.3 Selekcija

Selekcija je ključni korak u genetskom algoritmu koji omogućava odabir jedinki za reprodukciju u narednoj generaciji na osnovu njihove prilagođenosti. U našem projektu koristimo rulet (roulette wheel) selekciju, poznatu i kao selekciju proporcionalnu fitnessu.


Princip rada rulet selekcije zasniva se na proporcionalnom izboru: svaka jedinka dobija verovatnoću izbora proporcionalnu svojoj vrednosti funkcije prilagođenosti. To znači da jedinke sa većom fitness vrednošću imaju veću šansu da budu odabrane, dok one sa slabijom prilagođenošću imaju manju šansu, ali nisu potpuno isključene, što omogućava očuvanje genetske raznovrsnosti.

U implementaciji, prvo se fitness vrednosti svih jedinki prilagode tako da budu pozitivne — tako što se od svake vrednosti oduzima minimalna fitness vrednost u populaciji (što može biti negativna vrednost) i dodaje mali pozitivan parametar ϵ (epsilon), čime se izbegavaju negativne ili nula verovatnoće.

Verovatnoće izbora zatim se dobijaju normalizacijom ovih pomerenih fitness vrednosti tako da zbir verovatnoća bude 1.

Na slici 2 prikazan je vizuelni model rulet selekcije koji ilustruje kako se

verovatnoće odabira jedinki proporcionalno raspoređuju na „točku ruleta“, gde veće fitness vrednosti zauzimaju veće sektore.



Slika 2: Vizuelni prikaz principa rulet selekcije. Površina svakog sektora proporcionalna je fitness vrednosti jedinke, čime se ilustruje verovatnoća njenog odabira.

Odabrane jedinke se biraju nasumično prema ovim verovatnoćama, pri čemu se vrši odabir bez ponavljanja — jedna jedinka ne može biti izabrana dva puta u istom krugu selekcije.

Ovakav princip selekcije osigurava balans između eksploatacije najboljih rešenja i očuvanja raznovrsnosti populacije, što doprinosi efikasnijem pretraživanju prostora mogućih rešenja i izbegavanju lokalnih maksimuma.


4.4 Genetske operacije: ukrštanje i mutacija

Ukrštanje (Crossover): Ukrštanje je jedna od ključnih operacija genetskog algoritma, čija je osnovna funkcija stvaranje potomaka kombinovanjem genetskog materijala dve roditeljske jedinke. Cilj ove operacije je rekombinacija postojećih karakteristika u populaciji kako bi se generisala nova rešenja sa potencijalno boljim performansama.

U našem algoritmu koristi se adaptivni pristup dvo-tačkastog ukrštanja: ukoliko hromozom (kod jedinke) sadrži dovoljan broj gena (bitova), biraju se nasumično dve različite tačke prekida unutar hromozoma između kojih se vrši razmena genetskog sadržaja roditelja. Ova tehnika omogućava očuvanje i rekombinaciju većih genetskih segmenata, što povećava raznovrsnost potomaka i mogućnost pronalaženja kvalitetnijih rešenja u pretraživačkom prostoru.

Za manje hromosome, odnosno one sa manjim brojem bitova, primenjuje se jednostruko (jednotačkasto) ukrštanje, čime se izbegava stvaranje potomaka identičnih roditeljima.

Operacija ukrštanja se primenjuje sa verovatnoćom *crossover_prob* (u našem slučaju 0.9). Na taj način, određeni broj potomaka ostaje neizmenjen, što doprinosi očuvanju genetske raznovrsnosti i smanjuje rizik od pre-rane konvergencije algoritma.



Slika 3: Vizuelni prikaz principa dvo-tačkastog ukrštanja.

Mutacija: Mutacija je operacija nasumične modifikacije gena u hromozomu potomaka i služi za očuvanje i povećanje genetske varijabilnosti populacije. U našem modelu, mutacija se sprovodi tako što se nasumično biraju dve različite pozicije unutar hromozoma, a svi bitovi između njih se invertuju (bit-flip). Ovakav segmentalni pristup mutaciji omogućava značajnije promene u genetskom kodu u poređenju sa pojedinačnim bit-flipovima, čime se efikasnije istražuju nove oblasti prostora rešenja.

Mutacija se primenjuje sa verovatnoćom *mutation_prob* (kod nas tipično oko 0.2), što predstavlja optimalan kompromis između očuvanja dobrih osobina nasleđenih od roditelja i unošenja novih varijacija koje mogu poboljšati performanse algoritma. Bez ove operacije, genetski algoritam bi mogao da se zaglavi u lokalnim optimumima i ne bi uspevao da pronađe globalno najbolje rešenje.

4.5 Implementacija genetskog algoritma (GA)

U okviru ovog rada, genetski algoritam je prilagođen specifičnom problemu predviđanja nedostajućih vrednosti u RCBD (Randomized Complete

Block Design) eksperimentalnim podacima. Implementacija se zasniva na sledećim principima:

- **Kodiranje jedinki:** Svaka jedinka predstavlja potencijalnu vrednost nedostajućeg podatka enkodiranu binarnim hromozomom čija dužina zavisi od definisanog intervala mogućih vrednosti.
- **Funkcija prilagođenosti (fitness):** Evaluacija kvaliteta jedinke vrši se na osnovu negativne vrednosti sume kvadrata grešaka (SSE) između predviđenih i stvarnih vrednosti u tabeli.
- **Inicijalizacija populacije:** Početna populacija se generiše nasumično unutar validnog domena, pri čemu se obezbeđuje jedinstvenost jedinki kako bi se povećala genetska raznovrsnost od samog početka.
- **Genetske operacije:** Primena dvo-tačkastog ukrštanja sa verovatnoćom od 0.9 omogućava efikasno kombinovanje genetskog materijala roditelja, dok se mutacija sa verovatnoćom 0.2 koristi za inverziju bita u nasumično odabranom segmentu hromozoma, čime se povećava istraživačka sposobnost algoritma i izbegava zaglavljivanje u lokalnim maksimumima.
- **Elitizam:** Najkvalitetnije jedinke se direktno prenose u narednu generaciju, čime se osigurava očuvanje najboljih pronađenih rešenja tokom iteracija.
- **Iterativni razvoj:** Algoritam se izvršava kroz unapred definisan broj generacija, pri čemu se kontinuirano prati prilagođenost najboljih jedinki i druge metrike performansi, što omogućava analizu konvergencije i stabilnosti rešenja.

Ovakav pristup pruža robusno i efikasno sredstvo za predviđanje nedostajućih vrednosti u eksperimentalnim podacima, potvrđeno kroz detaljne eksperimente prikazane u daljem tekstu.

5 Eksperimentalni deo

Eksperimentalni deo projekta obuhvata pokretanje i evaluaciju genetskog algoritma na veštački generisanim i realnim podacima, sa ciljem procene njegove efikasnosti u imputaciji nedostajućih vrednosti u RCBD tabelama. Testiranje je sprovedeno sa ciljem da se proceni efikasnost i tačnost metode u

imputaciji nedostajućih vrednosti u RCBD tabelama (Randomized Complete Block Design).

U okviru eksperimenata analizirana je:

- **Funkcija prilagođenosti (fitness)** tokom više generacija, sa ciljem prikaza konvergencije algoritma i stabilnosti rešenja;
- **Kvalitet imputacije** poređenjem predviđenih vrednosti sa stvarnim vrednostima kada su u pitanju veštački podaci i korišćenjem *MAPE* (*Mean Absolute Percentage Error*) metrike za proveru stabilnosti predviđanja druge nedostajuće vrednosti kada u RCBD tabeli fale dve vrednosti.
- **Ponašanje algoritma** u scenarijima sa jednom i sa dve nedostajuće vrednosti, uključujući kodiranje jedinki, dekodiranje i evaluaciju.

U svrhu validacije, korišćena su dva tipa podataka:

- **Veštački podaci**, kod kojih su poznate i originalne i nepotpune RCBD tabele, što omogućava preciznu kvantitativnu analizu tačnosti algoritma;
- **Stvarni podaci**, kod kojih su dostupne samo RCBD tabele sa nedostajućim vrednostima. Za razliku od naučnog rada koji je poslužio kao osnova, u ovom projektu smo uključile i rad sa stvarnim podacima, u cilju povećanja praktične primenljivosti razvijenog rešenja. U realnim eksperimentima, kada dođe do gubitka vrednosti, izvorne vrednosti se obično ne mogu rekonstruisati, pa algoritam mora da donese procenu isključivo na osnovu poznatog ostatka tabele.

Posebna pažnja posvećena je i **upoređivanju performansi** implementiranog algoritma sa pristupom iz referentnog naučnog rada, koji je poslužio kao teorijski osnov za projekat. Cilj ovog poređenja bio je da se identifikuju eventualna poboljšanja u pristupu, fleksibilnosti i preciznosti.


5.1 Pokretanje genetskog algoritma nad veštačkim podacima

U ovom delu eksperimentalne analize genetski algoritam je pokrenut u dva scenarija: kada postoji jedna nedostajuća vrednost i kada su prisutne dve. Za potrebe eksperimenta korišćena je RCBD matrica dimenzija 5×5 , sa vrednostima u opsegu od 10 do 50.

5.1.1 GA za jednu nedostajuću vrednost

U ovom eksperimentalnom delu uklonjena je vrednost sa nasumične pozicije (0, 2), čija je originalna vrednost bila 20.0. Genetski algoritam je pokrenut nad inicijalnom populacijom veličine 10, za 20 generacija, uz veličinu elite od 2, verovatnoću mutacije 0.2 i verovatnoću ukrštanja 0.9.


Na slici 4 prikazan je prikaz vrednosti funkcije prilagođenosti (fitness) najbolje jedinice tokom trajanja generacija. Uočeno je da je funkcija prilagođenosti rastuća funkcija, koja oko 10. generacije dostiže optimalnu vrednost blisku nuli. To ukazuje na uspešnu konvergenciju algoritma.



Slika 4: Vrednost funkcije prilagođenosti najbolje jedinice tokom 20 generacija kada se predviđa jedna nedostajuća vrednost

Nakon završetka algoritma, iz populacije je izdvojena jedinka sa najvećom funkcijom prilagođenosti. Njena dekodirana vrednost iznosi 20.7, što predstavlja odstupanje od samo 0.7 u odnosu na stvarnu vrednost 20.0.

Na slici 5 prikazana je apsolutna razlika između stvarne vrednosti i najbolje dekodirane vrednosti tokom trajanja generacija. Uočava se stabilizacija razlike i brzo približavanje stvarnoj vrednosti već nakon nekoliko iteracija.



Slika 5: Apsolutna razlika između stvarne vrednosti i najbolje predviđene vrednosti kroz 20 generacija

5.1.2 GA za dve nedostajuće vrednosti

Nakon predviđanja jedne nedostajuće vrednosti, genetski algoritam je iskorišćen za predikciju dve nedostajuće vrednosti koje su nasumično uklonjene sa pozicija (0, 2) i (2, 2), pri čemu su njihove stvarne vrednosti bile 20.0 i 27.1.

Važno je napomenuti da se genetski algoritam u ovom slučaju koristi za direktnu procenu samo prve nedostajuće vrednosti, dok se druga vrednost izračunava posredno pomoću formule preuzete iz referentnog naučnog rada. Ta vrednost zavisi od predviđene vrednosti prve i predstavlja funkciju ostalih vrednosti u tabeli. Konkretno, koristi se sledeća formula [5]:

$$\hat{X}_{ij} = \frac{ay'_i + by'_j - y'}{(a-1)(b-1)}$$

gde su:

- y'_i – suma svih vrednosti u redu i (blok),
- y'_j – suma svih vrednosti u koloni j (tretman),


- y' – ukupna suma svih poznatih vrednosti u tabeli,
- a – broj redova (blokova),
- b – broj kolona (tretmana).

Nakon procene prve vrednosti, svaka jedinka se koristi za izračunavanje druge vrednosti korišćenjem ove formule. U svakom koraku se izračunava nova vrednost druge nedostajuće vrednosti i na osnovu toga se računa greška.


Za analizu stabilnosti procene druge vrednosti koristi se formula za srednju apsolutnu procentualnu grešku (MAPE), takođe preuzeta iz naučnog rada [5]:

$$\text{MAPE} = \frac{|\text{prethodna vrednost} - \text{nova vrednost}|}{\text{prethodna vrednost}}$$

Na slici 6 prikazana je vrednost funkcije prilagođenosti najbolje jedinke kroz 20 generacija, dok slika 7 prikazuje kako se MAPE za drugu nedostajuću vrednost ponašala kroz generacije.



Slika 6: Vrednost funkcije prilagođenosti najbolje jedinke tokom 20 generacija u slučaju kada se predviđaju dve nedostajuće vrednosti



Slika 7: Srednja apsolutna procentualna greška (MAPE) za drugu nedostajuću vrednost tokom 20 generacija

Kao što se vidi na grafiku funkcije prilagođenosti, algoritam brzo konvergira ka optimalnim vrednostima. Iz grafika na slici 7 može se uočiti da vrednosti MAPE greške opadaju kako algoritam napreduje kroz generacije. Oscilacije se tokom iteracija stabilizuju. Ovo ukazuje na to da se procena druge nedostajuće vrednosti, iako se računa indirektno, učvršćuje svoju vrednost. Drugim rečima, genetski algoritam konvergira ne samo ka preciznijoj prvoj vrednosti, već posredno i ka stabilnijoj i pouzdanijoj drugoj.

Najbolja pronađena vrednost za prvu nedostajuću vrednost iznosi 20.7, što predstavlja grešku od samo 0.7 u odnosu na stvarnu vrednost. Za drugu nedostajuću vrednost, dobijeni rezultat iznosi približno 29.48, što takođe pokazuje visok nivo tačnosti, uzimajući u obzir da se ona ne računa direktno već se dobija posredno.

Ovaj pristup pokazuje da je moguće proširiti genetski algoritam na slučaj sa više nedostajućih vrednosti, uz očuvanje dobrih performansi i tačnosti.

5.2 Pokretanje genetskog algoritma nad stvarnim podacima


Nakon rada sa veštačkim podacima, fokus je prebačen na scenario u kom RCBD tabela sadrži jednu nedostajuću vrednost, ali bez dostupne originalne vrednosti za poređenje. Ova situacija simulira realan slučaj, gde se ne zna

prava vrednost i oslonac mora da bude isključivo model da bi se izračunala SSE greška.

U ovom delu rada korišćeno je *model-based* račuanje greške. Budući da stvarna vrednost za poređenje ne postoji, vrednost predviđena od strane algoritma se ocenjuje kroz njeno odstupanje od ostatka vrednosti u istoj vrsti (bloku). Naime, prema pretpostavkama RCBD modela, greške eksperimentalnih merenja su nezavisne, imaju normalnu raspodelu i konstantnu disperziju. Zbog toga se očekuje da predviđena vrednost bude u skladu sa ostalim vrednostima u istom redu, odnosno da ne odudara značajno.

Kao i u prethodnom slučaju, korišćena je RCBD tabela dimenzija 5×5 iz koje je nasumično uklonjena jedna vrednost. U konkretnom primeru, vrednosti u vrsti u kojoj je vrednost uklonjena su: 7.0, 7.0, 11.0, 9.0. Genetski algoritam, pokrenut sa istim parametrima kao za veštačke podatke, predviđa vrednost 7.7, što pokazuje usklađenost sa postojećim vrednostima u toj vrsti.

Na slici 8 prikazana je vrednost funkcije prilagođenosti kroz 20 generacija. Uočeno je da vrednosti konvergiraju prema optimumu već u ranim iteracijama. To ukazuje da algoritam brzo nalazi rešenje koje je u skladu sa očekivanjima RCBD modela. Iako nije moguće kvantifikovati tačnost predikcije bez poznavanja stvarne vrednosti, stabilna konvergencija i usklađenost sa vrednostima u istom redu sugerišu da je predikcija statistički validna i opravdana.



Slika 8: Vrednost funkcije prilagođenosti najbolje jedinice tokom 20 generacija u slučaju kada se predviđa jedna vrednost bez dostupne tačne vrednosti za poređenje

5.3 Genetski algoritam iz literature

U ovom odeljku dat je sažet pregled razlika između razvijenog genetskog algoritma i algoritma predstavljenog u referentnom naučnom radu koji je glavni oslonac ovog projekta.

Prva i najznačajnija razlika odnosi se na izbor metrike za evaluaciju jedinki. U naučnom radu autori koriste MAPE (Mean Absolute Percentage Error) dok se u ovom radu koristi SSE (Sum of Squared Errors).

Takođe, u radu iz literature nisu analizirani stvarni podaci, tj. scenariji u kojima je nedostajuća vrednost zaista nepoznata i ne postoji referentna vrednost za poređenje. Ovaj rad je dodatno unapređen uključivanjem takvog scenarija, što doprinosi njegovoj praktičnoj primenljivosti.

U procesu kodiranja jedinki, dodat je i parametar ϵ prilikom određivanja granica vrednosti za jedinku. Ova korekcija omogućava da algoritam precizno predvidi i ekstremne vrednosti (minimum i maksimum) u okviru posmatranog reda, što u originalnom radu nije bilo implementirano.

Konačno, prilikom ukrštanja jedinki u ovom radu implementirane su dve varijante – one-point i two-point crossover – u zavisnosti od dužine jedinke, dok je u naučnom radu primenjena isključivo two-point crossover strategija.

U narednom odeljku sledi detaljno poređenje implementiranog algoritma sa onim iz literature, uz diskusiju o uočenim razlikama u performansama.

5.4 Upoređivanje razvijenog GA sa onim iz literature

Radi poređenja rezultata dobijenih u literaturi i u ovom radu iskorišćena je RCBD tabela koja je bila osnovna za eksperimentalnu evaluaciju GA u referentnom radu [5]. Tabela sadrži pet tretmana i pet blokova i data je u Tabeli 1.

	1	2	3	4	5
1	7	7	15	11	9
2	12	17	12	18	18
3	14	18	18	19	19
4	19	25	22	19	23
5	7	10	11	15	11

Tabela 1: RCBD tabela korišćena u eksperimentima

Genetski algoritam je pokretan kroz pet nezavisnih eksperimenata. U svakom eksperimentu menjane su vrednosti kontrolnih parametara, dok je algoritam uvek primenjivan nad istom RCBD tabelom, kako je rađeno i u naučnom radu. Vrednosti verovatnoće mutacije varirale su u intervalu od

0.05 do 0.09, sa korakom od 0.01. Verovatnoća ukrštanja kretala se od 0.90 do 0.98. Broj generacija povećavan je od 20 do 40 u koracima od po 5, dok je veličina elite određivana kao $\max(1, \frac{\text{broj generacija}}{5})$. Na ovaj način ispitivan je uticaj različitih kombinacija parametara na kvalitet rešenja.

Postupak je ponavljan za svaku vrednost iz RCBD tabele, odnosno svaka vrednost je naizmenično posmatrana kao nedostajuća. Nakon toga, za svaku poziciju u tabeli odabrana je najbolja predviđena vrednost među rezultatima pet eksperimenata. Svi dobijeni rezultati sačuvani su u datoteci `results_checkpoint.csv`.


Te najbolje vrednosti upoređene su sa najboljim vrednostima koje su autori u literaturi dobili primenom svog GA.

	Actual	Our Value	Their Value
0	7	7.0	6.9
1	7	7.0	8.1
2	15	11.3	17.0
3	11	10.9	11.0
4	9	9.0	10.0
5	12	12.0	12.0
6	17	17.0	16.9
7	12	12.0	11.0
8	18	17.9	18.1
9	18	18.1	17.0
10	14	17.9	13.9
11	18	18.0	18.3
12	18	18.0	18.0
13	19	19.0	19.0
14	19	19.0	19.0
15	19	19.0	19.0
16	25	23.4	23.0
17	22	22.0	22.0
18	19	19.1	23.0
19	23	23.0	23.1
20	7	9.6	7.0
21	10	10.0	10.0
22	11	11.0	11.0
23	15	11.4	14.0
24	11	11.0	11.0

Slika 9: Poređenje najboljih vrednosti ovog rada i najboljih vrednosti iz literature

Slika 9 prikazuje rezultate poređenja: na njoj se nalaze naše najbolje vrednosti naspram njihovih najboljih vrednosti za svaku poziciju u tabeli. Anali-

zom se uočava da razvijeni GA u većem broju slučajeva daje bliže rezultate stvarnim vrednostima u poređenju sa algoritmom iz literature. Ovo je dodatno potvrđeno histogramom (Slika 10), na kojem je prikazano koliko puta je naš algoritam dao precizniju procenu od algoritma iz literature. Histogram jasno pokazuje da smo u većini slučajeva ostvarili manju grešku, odnosno uspešnije predviđali nedostajuće vrednosti.



Slika 10: *Histogram poređenja uspešnosti predviđanja*

Ukupni rezultati pokazuju sledeće: u 10 slučajeva naš algoritam je dao bolje predviđanje, u 5 slučajeva algoritam iz literature, dok je u 10 slučajeva rezultat bio identičan.

Ova zapažanja ukazuju na to da promena metrike u okviru fitness funkcije, kao i uvođenje dodatnog ε parametra, dovode do robusnijih i preciznijih rezultata. Naš pristup se pokazao kao efikasniji, posebno u situacijama kada su nedostajuće vrednosti bile ekstremi u svojim redovima.

Eksperimenti su izvođeni na Amazon EC2 instanci tipa **c4.4xlarge**, sa 16 vCPU jezgara i 30 GB RAM memorije, pod Amazon Linux operativnim sistemom. Korišćenje udaljenog AWS okruženja bilo je neophodno zbog značajne vremenske zahtevnosti izvršavanja genetskog algoritma, koju lokalni računar nije mogao da podnese efikasno i stabilno. Za implementaciju i pokretanje eksperimentalnog dela korišćen je Python 3 interpreter, dok je radno okruženje bilo **Jupyter Notebook**, što je omogućilo pregledno programiranje, vizuelizaciju rezultata i iterativno podešavanje parametara algoritma.

6 Zaključak

Genetski algoritmi predstavljaju moćan i fleksibilan pristup za rešavanje problema procene nedostajućih vrednosti u eksperimentalnim podacima, što je naročito važno u statističkim dizajnim kao što je randomizovani kompletni blok dizajn (RCBD). U okviru ovog rada prikazali smo implementaciju i evaluaciju genetskog algoritma razvijenog sa ciljem da precizno popuni praznine u podacima i omogući dalju primenu standardnih metoda analize varijanse.

Rezultati dobijeni eksperimentima jasno pokazuju da razvijeni algoritam daje konkurentne, a u brojnim slučajevima i bolje rezultate u poređenju sa postojećim pristupima iz literature. Posebno je značajno to što se metod pokazao stabilnim i u slučajevima sa više nedostajućih vrednosti, što ukazuje na njegovu robusnost i primenljivost u realnim istraživačkim scenarijima. Vizuelizacija i numerička analiza rezultata potvrdile su da je naš pristup sposoban da zadrži strukturu podataka i očuva statističku konzistentnost, što je od ključne važnosti u daljim fazama eksperimentalne analize.

Ipak, treba naglasiti i određena ograničenja. Genetski algoritmi po svojoj prirodi zahtevaju veliki broj iteracija i evaluacija fitnes funkcije, što može dovesti do znatnog vremenskog opterećenja, naročito kod većih tabela ili složenijih modela. Iz tog razloga, korišćenje udaljenog računarskog okruženja (AWS EC2) bilo je neophodno, jer lokalni resursi nisu mogli da omoguće stabilno i dovoljno brzo izvršavanje. Ovaj aspekt jasno ukazuje da je efikasnost implementacije i optimizacija performansi jedno od ključnih pitanja za budući rad.

Na kraju, treba istaći da genetski algoritmi, iako zahtevni po pitanju resursa, nude izuzetnu fleksibilnost i sposobnost da pronađu kvalitetna rešenja u situacijama kada klasične metode zakazuju. Zbog toga njihov značaj u kontekstu statističkog modeliranja i obrade eksperimentalnih podataka ostaje nesporan, a ovaj rad pokazuje da su oni realna i vredna alternativa u rešavanju problema nedostajućih vrednosti u RCBD tabelama. Buduća istraživanja i optimizacije samo će dodatno doprineti njihovoj primeni i efikasnosti.

7 Literatura

- [1] Montgomery, D. C. (2017). *Design and Analysis of Experiments* (9th ed.). Wiley. https://www.researchgate.net/publication/362079778_Design_and_Analysis_of_Experiments_9th_Edition
- [2] Gomez, K. A., & Gomez, A. A. (1984). *Statistical Procedures for Agricultural Research* (2nd ed.). John Wiley & Sons. https://books.google.rs/books/about/Statistical_Procedures_for_Agricultural.html?id=PVN7_XRhpdUC&redir_esc=y
- [3] Moore, K. et al. *Quantitative Methods for Plant Breeding*. Iowa State University Press. <https://iastate.pressbooks.pub/quantitativeplantbreeding/chapter/randomized-complete-block-design/>
- [4] Goldberg, D. E. (1989). *Genetic Algorithms in Search, Optimization and Machine Learning*. Addison-Wesley. https://www2.fiit.stuba.sk/~kvasnicka/Free%20books/Goldberg_Genetic_Algorithms_in_Search.pdf
- [5] Azadeh, A., Ebrahimnejad, S., Saberi, M. (2013). Optimum estimation of missing values in randomized complete block design by genetic algorithm. *Computers and Electronics in Agriculture*, 93, 1-7. <https://www.sciencedirect.com/science/article/abs/pii/S0950705112001852>
- [6] Borak, B. (2014). Genetski algoritam za rešavanje lokacijskog problema snabdevača ograničenog kapaciteta u više nivoa. Diplomski rad, Matematički fakultet. <http://elibrary.matf.bg.ac.rs/bitstream/handle/123456789/1894/genetski%20algoritam.pdf?sequence=1>